Постобработка OCR паспортов РФ: отчёт

1. Задача и общая идея

Модель распознала паспорта; для каждого документа нужно решить: **принять** (и выдать значения полей) или **отклонить** (попросить переснять). Принятый документ с ошибкой обходится дороже отклонённого, поэтому решение принимает документ только при прохождении всех обязательных проверок (ниже). Если не пройдена хотя бы одна, документ отклоняется. Модели я не обучал: данных мало (3000 документов), а доля ошибок среди принятых порядка 1%, и более сложную модель на таком объёме нельзя было бы честно проверить. Решение это цепочка проверок.

Сокращения: **VIZ** – основная (видимая) часть паспорта; **MRZ** – две машиночитаемые строки внизу; **CV** – кросс-валидация; **CP** – верхняя доверительная граница Клоппера–Пирсона для доли ошибок.

2. Как решение обрабатывает документ

1. **Формат.** Номер, код подразделения, даты и пол приводятся к единому виду (например, «61 24 283968»).
2. **Номер и код из MRZ.** В MRZ есть контрольные цифры. Если все четыре сошлись, номер паспорта и код подразделения берутся из MRZ. Это исправляет цифровые ошибки OCR: на development полностью верных документов стало 1428 вместо 1344 (из 2400), порч не было.
3. **Сверка двух источников.** ФИО, пол и даты из VIZ должны совпасть с MRZ. Не совпало – отказ.
4. **Буква Ё.** MRZ не отличает Е от Ё, поэтому сверка тут бессильна. В train настоящее «Ё» в ФИО у 1 документа из 3000, а OCR выдаёт его у 22 (в 21 случае ошибочно). Документы с «Ё» в ФИО отклоняются.
5. **Длинные поля** (место рождения, орган выдачи). В MRZ их нет, второго источника нет. Требуется высокая уверенность в каждой букве. Кроме того, проверяется рамка: высота рамки поля делится на (число найденных строк × типичную высоту строки), и результат должен быть не больше 1,2. Так ловится потерянная строка: у оставшихся букв уверенность может быть 1,0, но рамка остаётся «двухстрочной».
6. **Действительность на 01.10.2026** (п. 24 Положения №2267). Паспорт выдаётся с 14 лет, до 20-летия действует как первый, до 45-летия как второй, с 45 лет бессрочный; после 20 и 45 лет есть 90 дней на замену. Отклоняются: некорректные даты, выдача до 14 лет или позже 01.10.2026, просроченный паспорт, а также документы, у которых с 20- или 45-летия прошло не более 90 дней: в этот период паспорт действителен до оформления нового, а оформлен ли он, по доступным полям установить нельзя. Возраст сам по себе причиной отказа не служит.

3. Пороги уверенности зависят от источника снимка

Снимки приходят из трёх источников. У web и mobile уверенность в нашем train не превышает примерно 0,998, у mobile_v2 она доходит до 1,0, поэтому единый строгий порог пропускал бы только mobile_v2. Пороги выбраны отдельно для каждого источника на development: минимальная уверенность по любой букве длинных полей и уверенность поля для ФИО, пола и дат.

Источник	Мин. уверенность букв в длинных полях	Уверенность остальных полей
web	0,995	0,998
mobile	0,99	0,99
mobile_v2	0,999	0,999

Выбор: для каждого источника перебраны пороги 0,99 / 0,995 / 0,998 (для mobile_v2 только 0,999), взят вариант с долей ошибок среди принятых не выше 1% и максимумом принятых. Пороги и правила зафиксированы до проверки на validation и после неё не менялись.

4. Результаты (принято, из них с ошибкой)

«Верно» значит, что совпали все 10 полей с эталоном и паспорт действителен по датам. Данные train разделены на development (2400) и validation (600) так, чтобы повторные снимки одного паспорта (6 пар) не разошлись по частям.

Выборка	Документов	Принято	С ошибкой	Доля ошибок	CP, 95%
Development (подбор порогов)	2400	290	2	0,69%	2,15%
Validation (использована дважды)	600	71	2	2,82%	8,60%
Вложенная CV: отложенные части (5 разбиений)	3000	213	4	1,88%	4,25%

Эталонная точка отсчёта: сырой вывод OCR целиком верен у 1680 из 3000 документов (56%). Справочник подразделений не помог: точное название органа из разметки найдено у 142 из 2400 документов, а замена на единственный вариант дала 3 исправления и 143 порчи.

5. Оставшиеся ошибки и почему не ноль

Четыре ошибки среди принятых. В трёх случаях (в ФИО: ХАСАНЗЯН, МУТЯНСКИЙ, КАБЛЯХБАР) VIZ и MRZ согласуются друг с другом, но расходятся с эталоном на одну букву. Без исходных изображений установить причину нельзя (ошибка эталона или одинаковая ошибка распознавания), поэтому все случаи учтены как ошибки. В четвёртой («АУЛ ДЖАМБИЧИ» вместо «ДЖАМБИУИ») OCR заменил букву в месте рождения при высокой уверенности; ни MRZ, ни проверка рамки такое не ловят. В train среди 7517 полей имён, где VIZ и MRZ согласуются, эталон расходится в 25 случаях: 14 из них связаны с Е/Ё (их закрывает правило про Ё), в остальных 11 буквы отличаются случайно (порядка 0,4% документов). Такие расхождения текущие проверки обнаружить не могут.

Почему допуск около 1%, а не ноль. В доступных данных есть ошибки, которые текущие проверки не позволяют обнаружить, поэтому нулевой уровень этим решением не достигнут. Допуск 1% на development выбран как рабочий компромисс между охватом и числом ошибок: единый строгий порог (0,999 для всех источников) принимал бы 190 документов на test вместо 357. Цена ошибки в задании числом не указана, поэтому выбор между этими вариантами остаётся за заказчиком; ограничение 1% вне development не подтвердилось (2,82% на validation).

6. Прогноз для test

В answers.jsonl 2000 записей: **357 принято, 1643 отклонено**. Качество на test не измерялось (разметки нет). **Ожидаемое число ошибочных среди принятых: около 7–10** (1,88% по CV даёт ≈7; 2,82% по validation даёт ≈10); верхняя граница по CV (4,25%) даёт ≈15. Это перенос доли с небольших выборок, а не измерение. На test доля mobile_v2 выше (21,5% против 9,7% в train), поэтому принято больше, чем на validation.

7. Ограничения

- Пороги подбирались на development; validation использована второй раз и больше не является независимой проверкой. Набор правил разрабатывался с использованием train.
- Подбор порогов неустойчив: в CV для mobile_v2 допустимый порог нашёлся лишь в одном из пяти разбиений. При повторном подборе на других данных охват и ошибки могут отличаться.
- Доверительные границы CP предполагают независимые документы; повторные снимки одного паспорта и сам подбор порогов это нарушают. «Ноль наблюдаемых ошибок» не означал бы «ноль ожидаемых».
- Проверяется только текстовое совпадение с эталоном и действительность по датам. Подлинность документа и иные основания недействительности по доступным полям не проверяются.
- Дата выдачи и дата рождения в MRZ без века: век берётся из VIZ и не угадывается.

8. Воспроизводимость

python postprocess.py data/test_predictions.jsonl answers.jsonl – Python 3.12, только стандартная библиотека, без интернета, справочников и разметки. Код: **postprocess.py** (решение по документу), **ocr_core.py** (проверки).