Паспортный OCR: пороги по источникам

Как работает решение

Сравниваются VIZ и MRZ; номер и код исправляются по четырём контрольным цифрам. Длинные поля - место рождения (Birth_place_ru) и орган выдачи (Issue_organization_ru). Сомнительные символы и потерянные строки длинных полей отсеиваются по уверенности и рамкам. Затем проверяется действительность на 01.10.2026. Python 3.12.0, CPU/offline, только стандартная библиотека; python postprocess.py INPUT.jsonl answers.jsonl. INPUT.jsonl - предоставленный входной файл, который передаётся аргументом и не входит в репозиторий.

Правило зафиксировано до второй validation и CV: источник определяет две независимые границы: min(char_conf) каждого длинного поля и conf непустых полей ФИО, пола, дат и двух длинных полей (набор B). Проверены 3×3 пары 0.99/0.995/0.998 для web/mobile и единственная пара 0.999/0.999 для mobile_v2. Выбор отдельно для каждого source: **наблюдаемая доля ошибок ≤1.00% без округления после всех проверок**, затем максимум принятых; равный охват разрешается в пользу меньших порогов.

Source	min длинных полей	conf в B
web	0.995	0.998
mobile	0.99	0.99
mobile_v2	0.999	0.999

Остальные правила сохранены: B проверяет полные имена, пол и YYMMDD по MRZ, не допускает конфликтов суффикса отчества; суффикс самостоятельно ничего не доказывает. MRZ не различает Е/Ё; отказ при «Ё» в ФИО; пустое отчество разрешено при подтверждении MRZ. У обоих длинных полей требуется полный char_conf и высота поля / (число строк × медианная высота строки) ≤1.2. Нет уверенности/рамок или неизвестен source - отказ. Цифры дат и век не угадываются.

Действительность по заданному алгоритму №2267: некорректные даты, выдача до 14-летия или после 01.10.2026 - отказ. Рубеж: 20-летие при выдаче до 20 лет; 45-летие при выдаче от 20 до 45; выдача с 45-летия - бессрочность. До рубежа включительно действителен; следующие 90 дней неопределённы и отклоняются, затем недействителен. Возраст сам по себе не причина отказа. Для 29 февраля отказ лишь когда трактовка 28 февраля/1 марта меняет категорию.

Критерий «ноль ошибок» заменён наблюдаемой долей ≤1% на development. **Нулевой риск не достигнут.** Validation используется повторно, во второй раз, и больше не является независимым holdout. Для сравнения оценивался вариант с единым порогом min=0.999.

Development: выбор и ошибки

В ячейках принято/ошибочно после всех проверок.

Source, min	conf=0.99	conf=0.995	conf=0.998
web, 0.99	235/3	224/3	154/2
web, 0.995	51/1	47/1	**37/0**
web, 0.998	1/0	1/0	1/0
mobile, 0.99	**141/1**	139/1	97/1
mobile, 0.995	34/0	34/0	27/0
mobile, 0.998	1/0	1/0	1/0

Mobile_v2: фиксированные 0.999/0.999 дают 112/1. У web 3/235=1.28% не проходит точное ограничение 1%; у выбранных источников доли 0%, 0.71%, 0.89%. Итого **290 принятых: 288 верно, 2 ошибочно, 2110 отклонено**, CP upper 95% 2.15%. Прежде принималось 112 документов. Две ошибки полностью учтены: tr_01765 (mobile), ХАСАНЗЯН вместо ХАОАНЗЯН; tr_02287 (mobile_v2), МУТЯНСКИЙ вместо МУТЯНСЖИЙ. VIZ/MRZ согласуются с выданными именами, но без изображений нельзя независимо установить ошибку разметки или совместную ошибку OCR. Подозрение на ошибку разметки не исключает документ из метрик.

Повторная validation и устойчивость

Параметры и код зафиксированы до второй прямой проверки validation. **Validation использована второй раз.** После неё и CV пороги не менялись.

Оценка	Принято	Ошибки	Отклонено	Доля ошибок	CP upper 95%
Development, 2400	290	2	2110	0.69%	2.15%
Validation #2, 600	71	2	529	2.82%	8.60%
Внешние CV-фолды, 3000	213	4	2787	1.88%	4.25%

Validation по source: web - 9 принято/1 ошибка, mobile - 38/0, mobile_v2 - 24/1. Ошибки: tr_01506 (mobile_v2), КАБЛЯХБАР вместо КАБЛЯЖБАР, несмотря на согласие VIZ/MRZ; tr_01665 (web), АУЛ ДЖАМБИЧИ РЕСП. АДЫГЕЯ вместо АУЛ ДЖАМБИУИ РЕСП. АДЫГЕЯ. Последняя - замена буквы в месте рождения: ни MRZ, ни проверка полноты рамкой её не исправляют. Обе ошибки учтены. Наблюдаемое ограничение 1% **не подтвердилось на validation**.

CV: пять фолдов по 600 документов, seed=42, 2994 группы; все 6 пар повторных снимков удержаны целиком. Балансируются source и исходное полное совпадение OCR. В каждом прогоне **пороги заново выбираются только на четырёх обучающих фолдах**, пятый оценивается без подгонки. Если ни одна пара порогов не даёт непустого принятия с ≤1% ошибок, source в этом прогоне отклоняется целиком. Это оценка устойчивости процедуры подбора, не независимая оценка ровно тех же трёх замороженных пар.

CV-фолд	Принято	Ошибки
1	39	0
2	39	0
3	28	0
4	43	1
5	64	3

Mobile стабильно выбирает 0.99/0.99. У web: однажды нет допустимого варианта, трижды выбирается 0.998/0.99, один раз 0.995/0.998. У mobile_v2 допустимый вариант есть лишь в одном прогоне; оба его ошибочных документа оказались в одном отложенном фолде. Внешние ошибки CV - те же четыре разобранных выше документа, все посчитаны. **Подбор неустойчив**: редкие ошибки сильно меняют допустимость источника и охват. Группировка и seed ради результата не менялись.

Проверка действительности применяется после фильтров качества. Из прошедших качество дополнительно отклонены на development 5 недействительных и 3 неопределённых, на validation - 3 недействительных и 1 неопределённый.

Test, проверки и ограничения

В answers.jsonl 2000 уникальных записей со всеми test-ID: **357 принятых, 1643 отказа** (прежде 190/1810). Качество test не измерялось. **Условный прогноз - около 10 ошибок** среди 357 принятых: 357 × 2/71. Это перенос повторно использованной validation, а не измерение; состав источников и малая выборка ограничивают надёжность прогноза.

При разработке алгоритм прошёл 44 автоматических теста. Сдаваемые модули postprocess.py и ocr_core.py побайтно совпадают с проверенной версией. В отдельной папке подтверждён запуск на Python 3.12.0 без site-packages: аудит разрешал чтение только модулей, стандартной библиотеки и переданного входа, запрещал сетевые обращения. Два запуска дали ответы, побайтно одинаковые с исходными; проверены формат, 2000 уникальных ID и полнота ответов. Разметка, справочники, интернет и исследовательские скрипты для запуска не нужны.

Пороговая семья и общие правила уже изучались на train; даже вложенная CV не устраняет это предварительное знакомство. Validation использована дважды напрямую и затем в составе train для CV. CP - номинальные односторонние границы Клоппера-Пирсона для биномиальной доли: зависимости повторов, подбор порогов и неоднородные политики фолдов ограничивают их интерпретацию. Даже ноль наблюдаемых ошибок не означал бы нулевого ожидаемого риска; здесь ошибки наблюдаются.